## Auto-évaluation

Renforcez vos fondamentaux de Python pour la Data Science en analysant les données de systèmes éducatifs

Exercice en 3 parties - Analysez des données de systèmes éducatifs



Un dernier doute ?
<ul> <li>Pour vérifier la qualité de votre travail :</li> <li>cochez les cases ci-dessous : elles indiquent que vous avez bien pris en compte chaque indicateur de réussite ;</li> <li>complétez votre fiche au fur et à mesure de votre progression dans votre exercice.</li> <li>renseignez, si besoin, la colonne "Notes" avec des commentaires sur vos livrables / vos étapes. Ils seront des points de discussion avec votre mentor pendant votre session de bilan / soutenance.</li> </ul>
Quand toutes les cases de ce document seront cochées, vous pourrez déposer vos livrables sur la plateforme.
Bonne réussite !

Compétences	Indicateurs de réussite de l'activité	Notes
	Exercice - Partie 1	
Appliquer des analyses statistiques descriptives et / ou naviguer visuellement au sein des données afin de	<ul> <li>J'ai vérifié que l'installation de JupyterLab (ou un équivalent) était fonctionnelle.</li> <li>J'ai importé Pandas, Matplotib et Seaborn sans erreur au sein du Notebook.</li> <li>Je suis capable d'expliquer ce que représente chaque ligne dans chaque jeu de données.</li> <li>J'ai calculé la taille des jeux de données avec Pandas.</li> </ul>	

détecter des anomalies.	☐ J'ai décrit le contenu des colonnes de chaque jeu de données en utilisant les méthodes fournies par Pandas.	
Supprimer / corriger les anomalies manuellement et à l'aide d'outils / logiciels de nettoyage des données adaptés.	<ul> <li>□ J'ai calculé le nombre de doublons avec Pandas et les ai supprimés.</li> <li>□ J'ai quantifié les valeurs manquantes par colonne dans les jeux de données.</li> <li>□ Mon traitement des valeurs manquantes est en cohérence avec la problématique métier.</li> <li>□ J'ai utilisé les filtrages à base de conditions de Pandas :</li> <li>□ pour supprimer les faux pays ;</li> <li>□ pour réduire le nombre d'indicateurs via une colonne contenant des catégories d'indicateurs.</li> <li>□ Ma matrice de corrélation est cohérente :</li> <li>□ elle a été calculée avec Pandas ;</li> <li>□ visualisée avec Seaborn ;</li> <li>□ utilisée pour filtrer les indicateurs redondants.</li> <li>□ Je suis capable d'expliquer le sens des coefficients de corrélation de Pearson et de Spearman.</li> <li>□ Je suis satisfait de l'utilisation des markdown.</li> </ul>	
	Exercice - Partie 2	
Appliquer des analyses statistiques descriptives et /	☐ J'ai utilisé la méthode group_by() de Pandas pour évaluer la qualité des indicateurs et des années (en termes de valeurs renseignées).	

ou naviguer visuellement au sein des données afin de détecter des anomalies.	<ul> <li>□ J'ai utilisé la méthode pivot_table() pour créer un jeu de données avec :</li> <li>□ comme lignes : des pays ;</li> <li>□ comme colonne : des indicateurs ;</li> <li>□ comme valeurs : des résultats d'agrégations d'années.</li> </ul>
	<ul> <li>Je suis satisfait de mon interprétation des résultats de la méthode describe() de Pandas.</li> <li>J'ai rendu visuelles et interprété les distributions d'une variable quantitative en utilisant Seaborn ou Matplotlib.</li> </ul>
	<ul> <li>J'ai nommé mes variables en respect des bonnes pratiques.</li> <li>J'ai implémenté au moins une fonction pour automatiser un traitement présent plusieurs fois dans le code.</li> <li>J'ai utilisé au moins une boucle for pour éviter de répéter manuellement un traitement/une analyse.</li> </ul>
	Exercice - Partie 3
Configurer l'environnement de travail nécessaire à l'exploitation des données	<ul> <li>J'ai installé Poetry.</li> <li>J'ai créé et rempli un fichier pyproject.toml en utilisant poetry init et/ou poetry add.</li> <li>Le code de mon Notebook fonctionne correctement au sein de l'environnement virtuel que j'ai créé.</li> </ul>

Présenter ses résultats			es		Je suis sa analyses. Je présen Je présen d'indicated Je suis sa titres lisibl Je me suis un interloc Je suis sa	te de mai te mes de urs, tout e tisfait de les pour p s efforcé cuteur de	anière pr démarche en préc e mon ut présente de clari e faible r	orécise l nes pou cisant le tilisatio ter mes rifier le niveau	e le conte our netto les hypo on des g es analys e lien ent u technic	enu de oyer le je othèses graphiq ses stat tre mes que.	chaque eu de do s sous-ja ues et ai istiques s résultat	fichier d nnées e centes. inclus d quand d	le donr et rédu des axe cela ét	nées. ire le no es et de ait perti	s nent.
----------------------------	--	--	----	--	--	---	--	--	---	---	--	--	--	---	------------